

高伟翔

男 | 23 岁 | 中共党员 | 浙江杭州 | +86 19032579100 | 18973489380@163.com

求职意向: AI 应用开发 | Agent 算法



教育经历

杭州电子科技大学 | 控制科学与工程 | 自动化 (人工智能) 学院 | 硕士

2024 年 9 月 - 至今

GPA: 4.40/5.00

荣誉: 华为奖学金、“华为杯”研究生数学建模国家级三等奖

研究成果: 第一作者在 SCI TOP 期刊 Applied Soft Computing (IF=7.2) 发表论文一篇。

怀化学院 | 电气工程及其自动化 | 电气与自动化工程学院 | 本科

2020 年 9 月 - 2024 年 6 月

GPA: 4.56/5.00

荣誉: 湖南省优秀毕业生、国家励志奖学金、全国大学生数学竞赛省二等奖

实习经历

有方大健康科技集团 | AI 应用开发实习生

2026 年 2 月 - 2026 年 8 月

方小集混剪 Agent:

- **混剪 Agentic Workflow:** 为企业营销素材平台方小集 (10k+ 视频素材) 设计 AI 混剪 Agentic Workflow, 基于 FastAPI 和 remix_jobs 状态机编排需求解析、故事板规划、场景召回、逐镜头确认、TTS 时长预验证、FFmpeg 异步渲染及飞书交付; 设置 Human-in-the-Loop 节点, 支持整体重排与局部换片两类反馈驱动重规划。
- **场景级 RAG 召回链路:** 将视频拆解为带时间戳、视觉描述的可检索片段, 利用 text-embedding-v3 将片段描述向量化后写入 PostgreSQL; 设计 Planner agent 将用户需求拆成多个视觉 Shot, 再对每个 Shot 进行向量、全文、标签/关键词三路召回, 并通过 RRF 融合与业务规则重排提升镜头匹配精度。
- **GRPO 后训练:** 以 Qwen2.5-7B-instruct 为底座, 采用 GRPO 优化结构化剪辑 Planner, 构造约 500 条训练 Prompt, 围绕 Schema、目标时长、裁剪区间、素材多样性和叙事连贯性等设计 7 维奖励函数, 评测集上 Schema 合法率 88.5% → 96.8%, 首轮 QA 通过率 63.3% → 78.9%。

灵枢-智能录音处理平台:

- **业务规模与平台闭环:** 面向门店技师、招商销售等场景每月约 53 万小时录音的处理需求, 构建从 Job API、分布式 ASR、Transcript 2.0、长录音语义分析, 到 PDF 报告和业务回调的端到端智能处理平台。
- **LLM Pipeline | 顶层编排与分析:** 基于 LangGraph 和 PostgreSQL 构建 Job 状态机与分析 DAG, 编排 ASR Submit、Transcript 校验、长录音切窗、窗口并行分析、结果聚合与报告回调; 使用 PostgreSQL Checkpointer 持久化执行状态, 并记录模型版本、Request ID、Token、延迟与成本。
- **ASR 集群 | 分布式推理与可靠性:** 基于 RocketMQ + 对象存储构建事件驱动 Worker Pool, 将预处理、FunASR 转写、CAM++ 说话人处理、标点恢复和后处理解耦部署; 通过 Inbox/Outbox、消费幂等、Worker Lease、重试与 DLQ 支持跨节点可恢复执行。
- **集群部署与性能优化:** 面向峰值单日约 2.2 万小时录音的容量需求, 基于 6 张 RTX 4090 完成分布式部署和角色资源配比, 针对预处理供给不足、GPU 空转与阶段阻塞, 将 Chunk 处理重构为流式生产者-消费者模式, 并结合动态 Batch、阶段并行与 Worker 资源配比, 使 ASR 完整链路实测吞吐达到 900 × 以上 (1s 实际时间可处理 900s 音频)。

杭州小影创新科技股份有限公司 | AIGC 算法实习生

2025 年 11 月 - 2026 年 2 月

- **视觉模型选型与优化:** 针对侧脸、遮挡、低光照等失败模式, 对比 MediaPipe 与 SegFormer 后完成分割方案替换, 并引入 ViT Detection 锁定多人物场景下的目标人物, 避免其他人物被同步编辑; 设计基于分割区域像素面积阈值的动态筛选机制, 在多段 ≥ 1h 长视频测试中显著降低异常帧概率并减少无效生成; 针对 50 个线上低相似度 Case 专项测试, 新工作流相似度提升至 90%。
- **工程化落地与部署优化:** 基于 ComfyUI 搭建了端到端长视频角色替换工作流并完成工程化落地, 开发自定义处理节点实现多模型级联调度与异常帧处理逻辑, 支撑电商营销视频中的人物替换与长视频一致性优化。同时针对多模型同时驻留导致 VRAM 峰值超出线上机器规格的问题, 设计模型按需加载、动态卸载、推理量化策略, 将 VRAM 峰值由 60 GB 降至 32 GB 以内, 满足线上部署需求。

西湖灵犀科技 (杭州) 有限公司-西湖大学 CenBRAIN 实验室 | 算法工程师实习生

2025 年 6 月 - 2025 年 9 月

- **多模态解码模型设计:** 负责临床 sEEG 数据采集与处理, 采用 CNN+Transformer 构建 sEEG Encoder (时序信号) 提取时空特征, 结合冻结的 BART-Chinese Encoder 作为 TextEncoder (汉字文本), 实现跨模态语义对齐。
- **模型训练框架:** 预训练阶段采用 InfoNCE Loss 跨模态对比学习+15% 随机掩码重构学习脑电-文本对齐; 微调阶段接入 BART-Chinese Decoder 通过 Cross-Attention 进行自回归生成; 采用 LoRA (rank=8) 完成 SFT, 在多受试者训练、单个未见受试者测试设置下取得 BLEU-4 0.403。

技能特长

Agent: LangGraph、LangChain、FastMCP、RAG、Tool Calling、Human-in-the-Loop、Agentic workflow、GRPO
后端: Python、FastAPI、SQLAlchemy、PostgreSQL、pgvector、Redis、RocketMQ
工程 / AI Coding: Docker、Linux、MinIO/OSS、FFmpeg、GitHub Actions、Git、Codex、Claude Code
LLM / 训练: PyTorch、Transformer、FunASR、CAM++、LoRA、SFT、Stable Diffusion、DDPM
语言: CET-6 499, 能阅读英文技术文档和论文。